INTELIGENCIA DE NEGOCIOS

Producción y paros de líneas de envasado

Vinilos y témperas

Modelo dimensional, ETL reproducible, PostgreSQL, Grafana y Power BI

Integrantes
Alejandro Ocampo
Santiago Zapata

Repositorio
https://github.com/zephyrDev00/ProyectoFinal_AlejandroOcampo_SantiagoZapata

Informe final del proyecto

Institución Universitaria Pascual Bravo

Medellín

2026

Resumen ejecutivo

La solución transforma el registro manual histórico de producción y paros de cuatro líneas de envasado en un repositorio analítico PostgreSQL. Un ETL en Python limpia, valida, concilia y carga el modelo dimensional; Grafana usa una tabla horaria simulada para monitoreo por línea y alerta; Power BI consume el modelo para el análisis mensual, anual y por causa de paro.

El resultado permite separar dos decisiones que el Excel no resuelve simultáneamente: la supervisión casi en tiempo real para operación y mantenimiento, y el análisis certificado para gerencia. El OEE se mantiene explícitamente no calculable porque el origen no registra ciclo ideal, unidades buenas ni unidades rechazadas; en su lugar se reportan indicadores trazables y una disponibilidad proxy con sus límites declarados.

Objetivo general

Diseñar, implementar y desplegar de forma contenerizada una solución de Inteligencia de Negocios de extremo a extremo que integre los registros históricos de producción y paros de las líneas Vinilos_1 a Vinilos_4 en un modelo dimensional PostgreSQL, mediante un ETL reproducible y auditado. La solución habilita un tablero operativo Grafana con simulación horaria y alertas, y un tablero analítico Power BI para decisiones estratégicas sobre producción, paros y disponibilidad.

Hallazgos y recomendaciones principales

Hallazgo	Evidencia	Implicación
Faltantes de contexto	3.912 registros sin turno y 3.874 sin referencia	No se imputan; se cargan como SIN TURNO y SIN REFERENCIA.
Producción incompleta	3.051 registros sin pacas y 3.049 sin horas operativas	Los nulos se conservan y no se convierten en cero.
Dos conceptos de tiempo	Paro detallado 8.449,6517 h y horas no trabajadas 41.519,85 h	No se combinan; se requiere definición de negocio para disponibilidad certificada.
OEE incompleto	No hay ciclo ideal ni cantidad buena/rechazada	OEE se muestra como no disponible, no como cero.
Códigos heterogéneos	Desfase entre 17, 18 y 19 códigos en P-MTO-22 y valores heredados	La causa no mapeada permanece visible en el Pareto.

```
[Running] python -u "c:\Users\ALEJANDRO\Desktop\Trabajo\BI_ProyectoFinal\etl\load.py"
{
  "run_id": 4,
  "source_rows": 8208,
  "accepted": 8208,
  "rejected": 0,
  "downtime_events": 16532,
  "quality": {
    "blank_rows": 0,
    "duplicate_content": 42,
    "invalid_date": 0,
    "unknown_machine": 0,
    "negative_measure": 0,
    "missing_shift": 3912,
    "missing_reference": 3874,
    "downtime_reconciliation_abs_gt_0_02h": 0,
    "legacy_unmapped_stop_rows": 0
  }
}

[Done] exited with code=0 in 451.438 seconds
```

Contexto, usuarios e insumos

La empresa fabrica vinilos y témperas con cuatro líneas de envasado. Las operarias registran producción y paros en formato manual; mantenimiento consolida la información en un libro XLSM. El Excel contiene los registros históricos, catálogos y tablas dinámicas, pero no ofrece trazabilidad de cambios, control de calidad reproducible ni monitoreo continuo.

Usuarios y preguntas de negocio

Usuario	Pregunta de negocio	Capa y frecuencia
Gerencia y comité	¿Cómo cambia la producción por año, mes, máquina y referencia? ¿Qué causas justifican inversión?	Power BI; mensual y trimestral.
Coordinación de mantenimiento	¿Qué causas concentran el paro? ¿Qué máquina y subcausa priorizar?	Power BI y Grafana; diario y mensual.
Supervisión de línea	¿Qué línea presenta paro crítico durante la hora actual?	Grafana; actualización cada minuto.
Analista BI	¿Qué filas se aceptaron y qué controles de calidad fallaron?	PostgreSQL y DBeaver; en cada carga.

Insumos y uso

Insumo	Uso en la solución
SEGUIMIENTO TEMPERAS Y VINILOS Actividad.xlsm	Fuente histórica: producción, horas, referencias, turnos, códigos y duraciones de paro.
P-MTO-22 Registro de paros de producción	Reglas de negocio, categorías oficiales de paro e indicadores reportados por el proceso.
Repositorio GitHub	Código ETL, DDL, consultas, dashboard Grafana, proyecto PBIP, documentación y guía de reproducción.

Alcance y límites

- El histórico se consume desde PostgreSQL. Power BI y Grafana no leen directamente el Excel.
- El monitoreo horario es una simulación controlada; no representa señales de PLC o SCADA.
- Los nombres de operarias y personal de mantenimiento no se cargan al modelo ni a los tableros.

Diagnóstico de la fuente y calidad de datos

La hoja Base De Datos tiene encabezado en la fila 9, 58 columnas y 8.208 registros con contenido. Cubre del 1 de enero de 2022 al 28 de marzo de 2025. La granularidad observada es un registro fuente por fecha, línea, turno y referencia cuando dichos atributos están presentes. Se identifican cuatro máquinas válidas: Vinilos_1 a Vinilos_4.

Control	Antes	Tratamiento y efecto
Filas con contenido	8.208	8.208 aceptadas en la fuente revisada; fecha y máquina válidas.
Duplicados de contenido	42 filas excedentes	Se conservan: no hay identificador confiable para probar que sean eventos duplicados.
Turno nulo	3.912 (47,7%)	Se carga como SIN TURNO; no se imputa.
Referencia nula	3.874 (47,2%)	Se carga como SIN REFERENCIA; no se imputa.
Pacas sin valor numérico	3.051 (37,2%)	Se conserva NULL: desconocido no equivale a cero.

Control	Antes	Tratamiento y efecto
Horas trabajadas sin valor	3.049 (37,1%)	Se conserva NULL.
Medidas negativas	0 en esta fuente	El ETL las rechaza y la base las restringe.
Conciliación paro	0 diferencias > 0,02 h	Slots de detalle concilian con Tiempo de Paro reportado.

Diagnóstico estructural del libro XLSM y del modelo PowerPivot heredado: El archivo SEGUIMIENTO TEMPERAS Y VINILOS Actividad.xlsm consta de 21 hojas de cálculo, 8 tablas dinámicas, segmentadores (slicers), rutinas VBA (vbaProject.bin) para captura mediante formulario y un modelo embebido en PowerPivot (Analysis Services VertiPaq) compuesto por dos tablas desnormalizadas: Base_datos_1 y Base_datos_subcodigos.

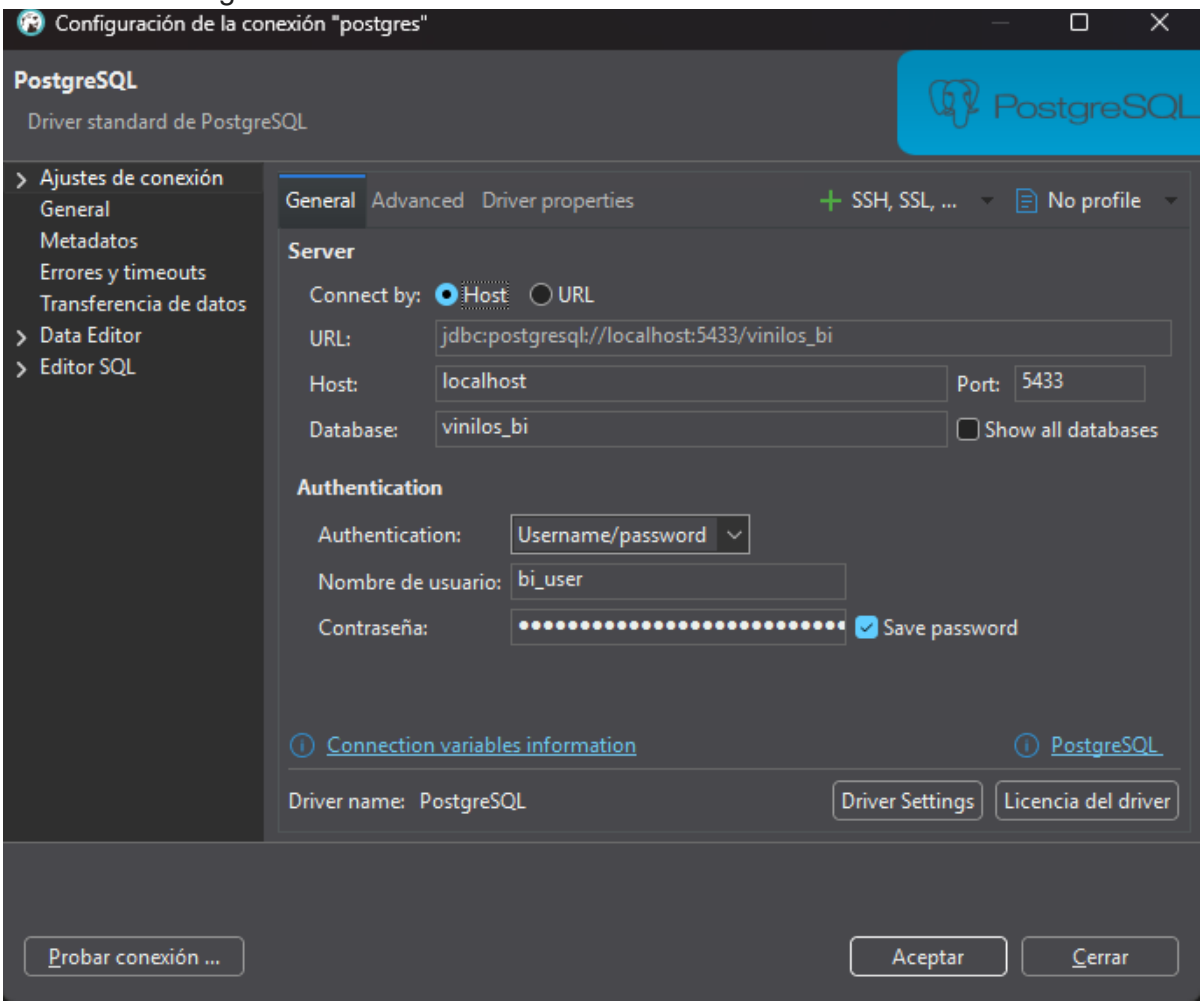
Se identificaron cuatro limitaciones críticas en la arquitectura heredada:

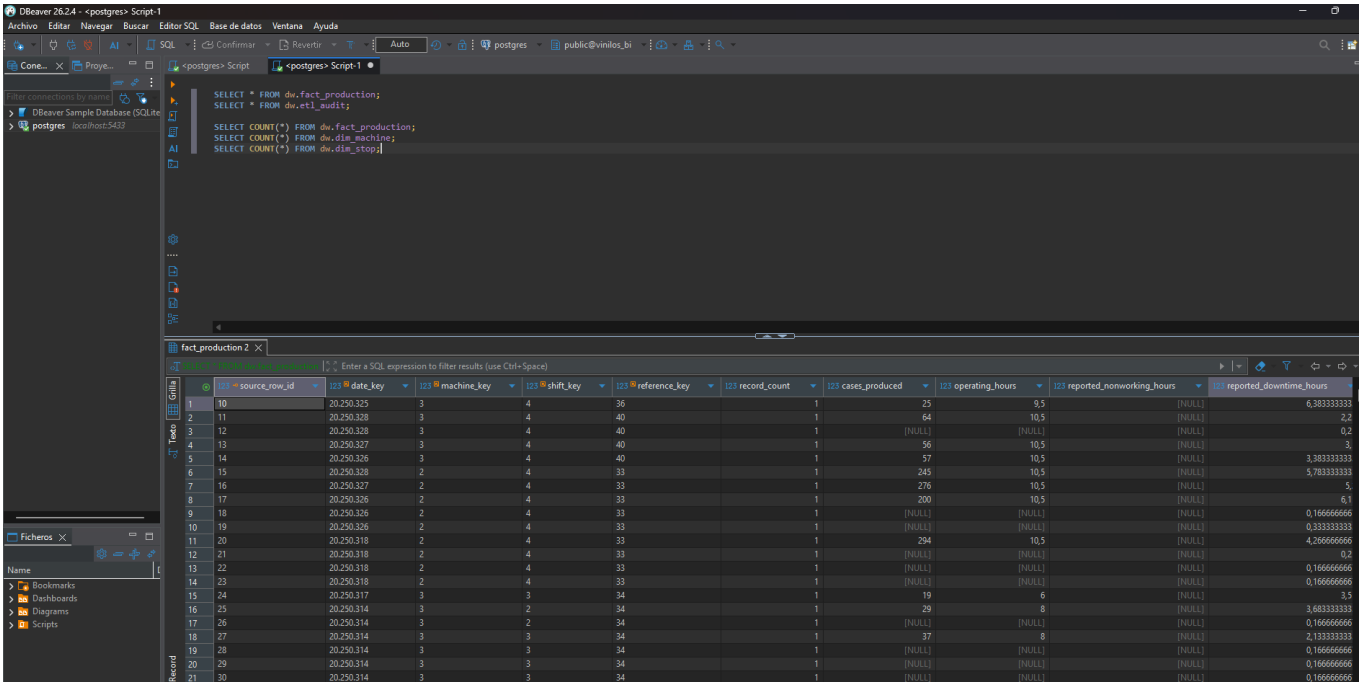
1. **Antipatrón de tabla ancha (*Repeating Groups*):** La hoja Base De Datos almacena los códigos de paro del 1 al 17 en columnas paralelas (Codigo de paro 1, Codigo 2 en horas, ..., Codigo 17 en horas), lo que impide agregar o filtrar causas dinámicamente sin modificar todas las tablas dinámicas.
2. **Fragmentación de subcódigos:** Los subcódigos mecánicos, eléctricos y de ajuste operativo (códigos 01, 03 y 05) se gestionan en una estructura paralela (Base_datos_subcodigos) que incluye los campos Área involucrada en subcodigo 5 y Personal involucrado, rompiendo la integridad referencial con el registro principal de producción.
3. **Errores de formulación en medidas implícitas de PowerPivot:** En el script MDX del modelo interno del Excel se evidenció que indicadores porcentuales como [% codigo 1] y [% codigo 3] estaban definidos dividiendo el **recuento de celdas no vacías (COUNTA)** sobre la suma de horas trabajadas ([Recuento de Codigo 1 a horas] / [Suma de Horas trabajadas]), en lugar de sumar la duración real en horas.
4. **Desfase documental en el procedimiento P-MTO-22:** Mientras la sección 4 del documento P-MTO-22 lista 17 códigos de paro ([01] a [17]), el formulario de captura y los gráficos gerenciales del mismo procedimiento incluyen el [18] Desinfección y el [19] No aplica, además de omitir en la base digital la columna NO CONFORME presente en el formato físico de planta F-PRO-33.

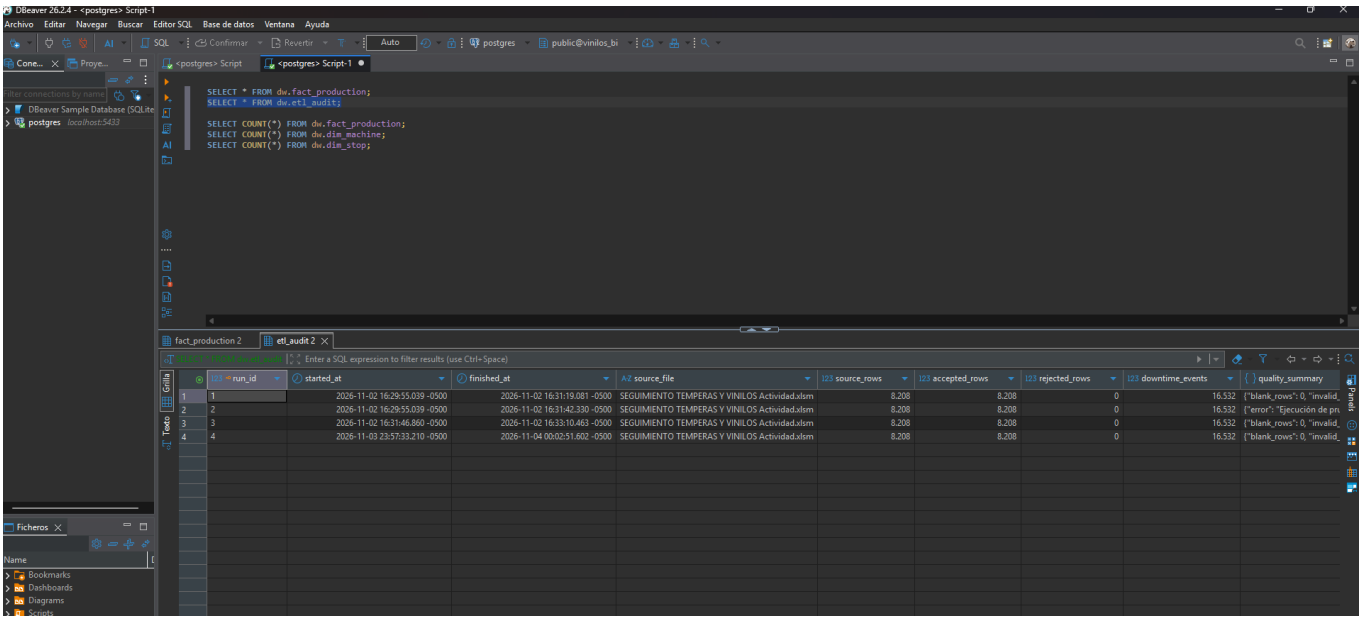
Reglas de limpieza y transformación

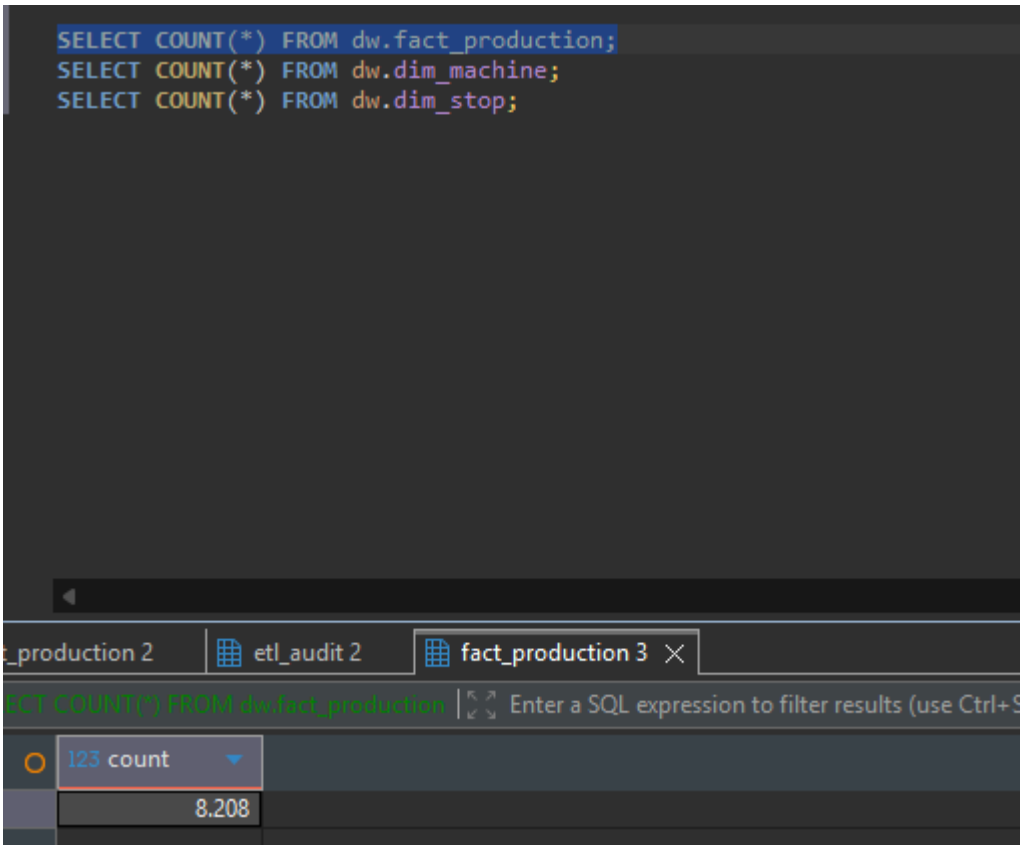
- Se rechaza una fila sin fecha interpretable, máquina fuera de las cuatro líneas o medida negativa.
- Se generan claves sustitutas y la fecha de negocio se deriva del campo Fecha, no de columnas Año/Mes no confiables.
- Turno y referencia ausentes reciben miembros explícitos para conservar el hecho y permitir medir el problema.
- Las causas heredadas o ambiguas no se inventan: se conservan como no mapeadas en dim_stop.

- Cada ejecución reemplaza la instantánea histórica dentro de una transacción; un bloqueo asesor evita dos cargas históricas concurrentes.






SELECT * FROM dw.fact_production;
SELECT * FROM dw.etl_audit;
SELECT COUNT(*) FROM dw.fact_production;
SELECT COUNT(*) FROM dw.dim_machine;
SELECT COUNT(*) FROM dw.dim_stop;
fact_production 2
etl_audit 2
run_id
started_at
finished_at
source_file
source_rows
accepted_rows
rejected_rows
downtime_events
quality_summary
1 2026-11-02 16:29:55.039 -0500 2026-11-02 16:31:19.081 -0500 SEGUIMIENTO TEMPERAS Y VINILOS Actividad.xlsm 8.208 8.208 0 16.532
2 2026-11-02 16:29:55.039 -0500 2026-11-02 16:31:42.330 -0500 SEGUIMIENTO TEMPERAS Y VINILOS Actividad.xlsm 8.208 8.208 0 16.532
3 2026-11-02 16:31:46.860 -0500 2026-11-02 16:33:10.463 -0500 SEGUIMIENTO TEMPERAS Y VINILOS Actividad.xlsm 8.208 8.208 0 16.532
4 2026-11-03 23:57:33.210 -0500 2026-11-04 00:02:51.602 -0500 SEGUIMIENTO TEMPERAS Y VINILOS Actividad.xlsm 8.208 8.208 0 16.532

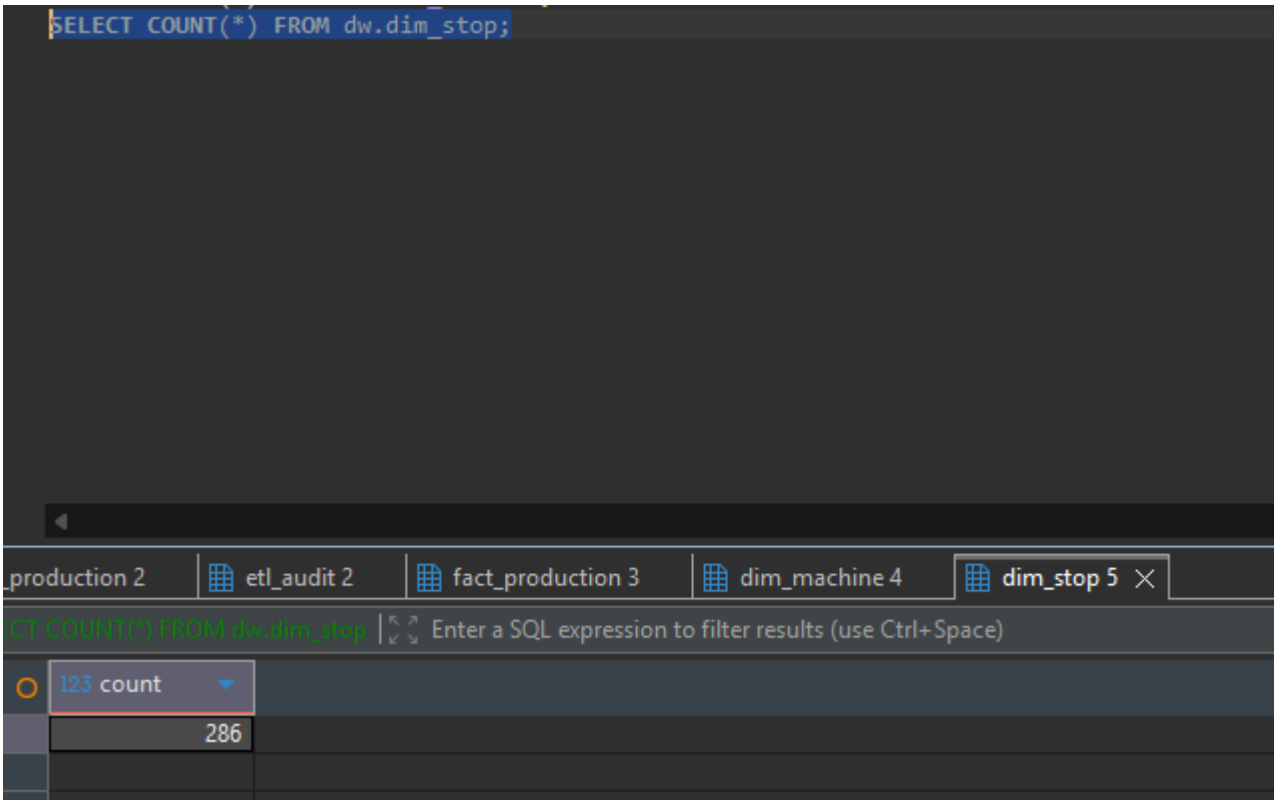

SELECT COUNT(*) FROM dw.fact_production;
SELECT COUNT(*) FROM dw.dim_machine;
SELECT COUNT(*) FROM dw.dim_stop;
etl_audit 2
fact_production 3
Enter a SQL expression to filter results (use Ctrl+
123 count
8.208

```sql
SELECT COUNT(*) FROM dw.dim_machine;
SELECT COUNT(*) FROM dw.dim_stop;
```

t_production 2 | etl_audit 2 | fact_production 3 | dim_machine 4

ECT COUNT(*) FROM dw.dim_machine | Enter a SQL expression to filter results (use Ctrl+Space)

123 count
4



Conciliación

La carga revisada concilia 378.778 pacas reportadas, 38.063,35 horas trabajadas, 41.519,85 horas no trabajadas y 8.449,6517 horas de Tiempo de Paro. El detalle de slots suma también 8.449,6517 horas. Las horas no trabajadas no se equiparan al paro detallado porque la diferencia de 33.070,20 horas carece de una definición de negocio confirmada.

Catálogo de indicadores

Las métricas se calculan al menor grano compatible con el dato disponible. Los umbrales operativos son demostrativos y no constituyen metas aprobadas de planta.

Indicador y fórmula	Unidad y grano	Meta fuente usuario
Pacas = SUM(cases_produced)	Pacas; línea, turno, referencia, día/mes/año	Sin meta confirmada; Excel; gerencia.
Horas operativas = SUM(operating_hours)	Horas; línea, turno, referencia, periodo	Sin meta confirmada; Excel; gerencia.
Paro detallado = SUM(duration_hours)	Horas; línea, turno, causa, periodo	Priorizar Pareto; slots de paro; mantenimiento.
Disponibilidad proxy = operación / (operación + no trabajadas)	Porcentaje; línea y mes	Meta por aprobar; campos K y M; supervisión.
Pacas por hora = pacas / horas operativas	Pacas/h; línea y mes	Línea base; Excel; gerencia.
Variación interanual = (pacas - pacas año anterior) / pacas año anterior	Porcentaje; mismo periodo comparable	Comparación analítica; dim_date; gerencia.
Paro móvil 60 min = paro_min / plan_min	Porcentaje; máquina-hora	Alerta > 20%; fact_live_hour; supervisión.
OEE = disponibilidad x rendimiento x calidad	Porcentaje; máquina-turno-referencia	No calculable: faltan ciclo ideal, buenas y rechazadas.
% Participación de código/subcódigo de paro = SUM(duration_hours) / CALCULATE(SUM(duration_hours), ALLSELECTED(dim_stop))	Porcentaje (%); máquina, causa, subcausa (códigos 01, 03, 05), mes y año	Minimizar causas vitales (80/20); reportado hoy en P-MTO-22; Coordinación de mantenimiento.

Indicador y fórmula	Unidad y grano	Meta fuente usuario
Rendimiento / Eficiencia teórica (P-MTO-22) = Pacas reales / Meta de pacas del turno	Porcentaje (%); línea, mes y año (comparativo 2024 vs 2025)	Meta ≥ 85% en P-MTO-22; no certificable en BD porque Base De Datos tiene vacíos en Unidades/min, Unidad/display y Display/paca, y omite la columna física NO CONFORME de F-PRO-33; Gerencia.

Indicadores propuestos

Además de los valores reportados actualmente, se propone medir la variación interanual de pacas, el Pareto de paro por causa/subcausa y el paro móvil de 60 minutos. Estas métricas no sustituyen el OEE; hacen visible la tendencia, la concentración de pérdidas y la reacción requerida durante la operación.

Adicionalmente, las columnas Unidades producidas cada minuto, Unidad por display y Display por paca del Excel presentan vacíos que impiden certificar el Rendimiento real, mientras que el campo físico NO CONFORME del formato F-PRO-33 no fue digitalizado en la hoja Base De Datos.

Modelo dimensional y bus de procesos

Se eligió un **modelo en estrella con dimensiones desnormalizadas** (conformando una constelación al compartir dim_date, dim_machine, dim_shift y dim_reference entre los procesos de producción y paros) en lugar de un esquema en copo de nieve (*snowflake*) porque reduce el número de JOINs en las consultas de PostgreSQL y optimiza el motor columnar VertiPaq de Power BI mediante relaciones directas de un solo salto (1:*).

Modelado de la jerarquía de paros (dim_stop): En el procedimiento **P-MTO-22** y en el libro Excel, la jerarquía de paros es **asimétrica (ragged hierarchy)**: existen códigos de nivel 1 (del [01] al [18]/[19]), pero únicamente los códigos **[01] Falla electromecánica**, **[03] Sistemas de potencia** y **[05] Ajuste operativo** poseen un segundo nivel de detalle (subcódigos como 1.2.C Cambio de Válvula, 3.2 Fallo en la red pública o 5.2 Sistema de dosificación, además de área y personal involucrado). Si se hubiera normalizado en dos tablas (dim_causa y dim_subcausa en copo de nieve), el 83% de las causas habría requerido registros ficticios o LEFT JOINs constantes. Al consolidar la jerarquía stop_code / stop_label → subcode / sublabel dentro de dim_stop (286 combinaciones únicas auditadas), se habilita el *drill-down* directo en Power BI sin perder las causas heredadas o sin subcódigo.

Grano declarado de las tablas de hechos

Tabla	Descripción y grano	Llaves
fact_production	Una fila por registro no vacío de la hoja Base De Datos. Representa producción y horas reportadas de la fila fuente.	PK source_row_id; FK date_key, machine_key, shift_key, reference_key.
fact_downtime	Una fila por slot de duración de paro positiva dentro de una fila de producción.	PK downtime_id; FK source_row_id, stop_key; UNIQUE source_row_id + source_slot.
fact_live_hour	Una fila por máquina y hora de simulación/telemetría.	PK hour_start + machine_key; FK machine_key y shift_key opcional.

Dimensiones y jerarquías

Dimensión	Atributos y jerarquía	Decisión de modelado
dim_date	full_date, día, mes, nombre mes, trimestre, año, semana ISO, día semana, fin de semana. Jerarquía Año > Trimestre > Mes > Fecha.	Construida por el equipo desde fecha real.
dim_machine	Código, nombre, número de línea, activo.	Conformada para producción, paro y estado horario.
dim_shift	Código, nombre, hora inicio/fin y grupo.	SCD1 actual; se requerirá SCD2 con vigencia efectiva.
dim_reference	Nombre, familia, tamaño nominal.	Conserva SIN REFERENCIA cuando el origen no informa valor.

Dimensión	Atributos y jerarquía	Decisión de modelado
dim_stop	Código, etiqueta, subcódigo, subetiqueta, área, responsable, nivel y mapeo. Jerarquía causa > subcausa.	Desnormalizada para drill-down simple; no mapeadas visibles.

Matriz de bus

Proceso	Fecha	Máquina	Turno	Referencia	Paro
Producción	X	X	X	X	
Paros	X	X	X	X	X
Estado horario	Hora	X	X		

Análisis e implementación propuesta de Slowly Changing Dimensions (SCD):

En el modelo dimensional se identificaron dos dimensiones cuyos atributos descriptivos evolucionan en el tiempo y requieren estrategias diferenciadas de preservación histórica:

1. **dim_shift (Dimensión de Turnos) — SCD Tipo 2:** En los registros históricos del Excel se observan variaciones en la configuración horaria de los turnos (conviven esquemas de 8 horas como 6am-2pm (Turno 1), 2pm-10pm (Turno 2) y 10pm-6am (Turno 3) con jornadas extendidas como 6am-4:30pm, 6am-6pm y 6pm-6am). Aplicar **SCD Tipo 1** (sobrescritura) alteraría retroactivamente las horas teóricas planificadas de los periodos cerrados. Por ello, se define **SCD Tipo 2** incorporando clave sustituta (shift_key), clave natural (shift_code), duración teórica del turno y metadatos de vigencia (valid_from DATE, valid_to DATE, is_current BOOLEAN).
2. **dim_stop (Dimensión de Causas y Subcausas de Paro) — SCD Tipo 2 / Híbrido (Tipo 1 + Tipo 2):** La estandarización de códigos heredados hacia el catálogo oficial del P-MTO-22 y las eventuales reasignaciones del atributo responsable o área (Operarios vs. Personal de mantenimiento, como ocurre en el código 05) requieren **SCD Tipo 1** para correcciones ortográficas de etiquetas y **SCD Tipo 2** cuando una subcausa cambia de área responsable en la planta, preservando la trazabilidad de auditoría histórica.

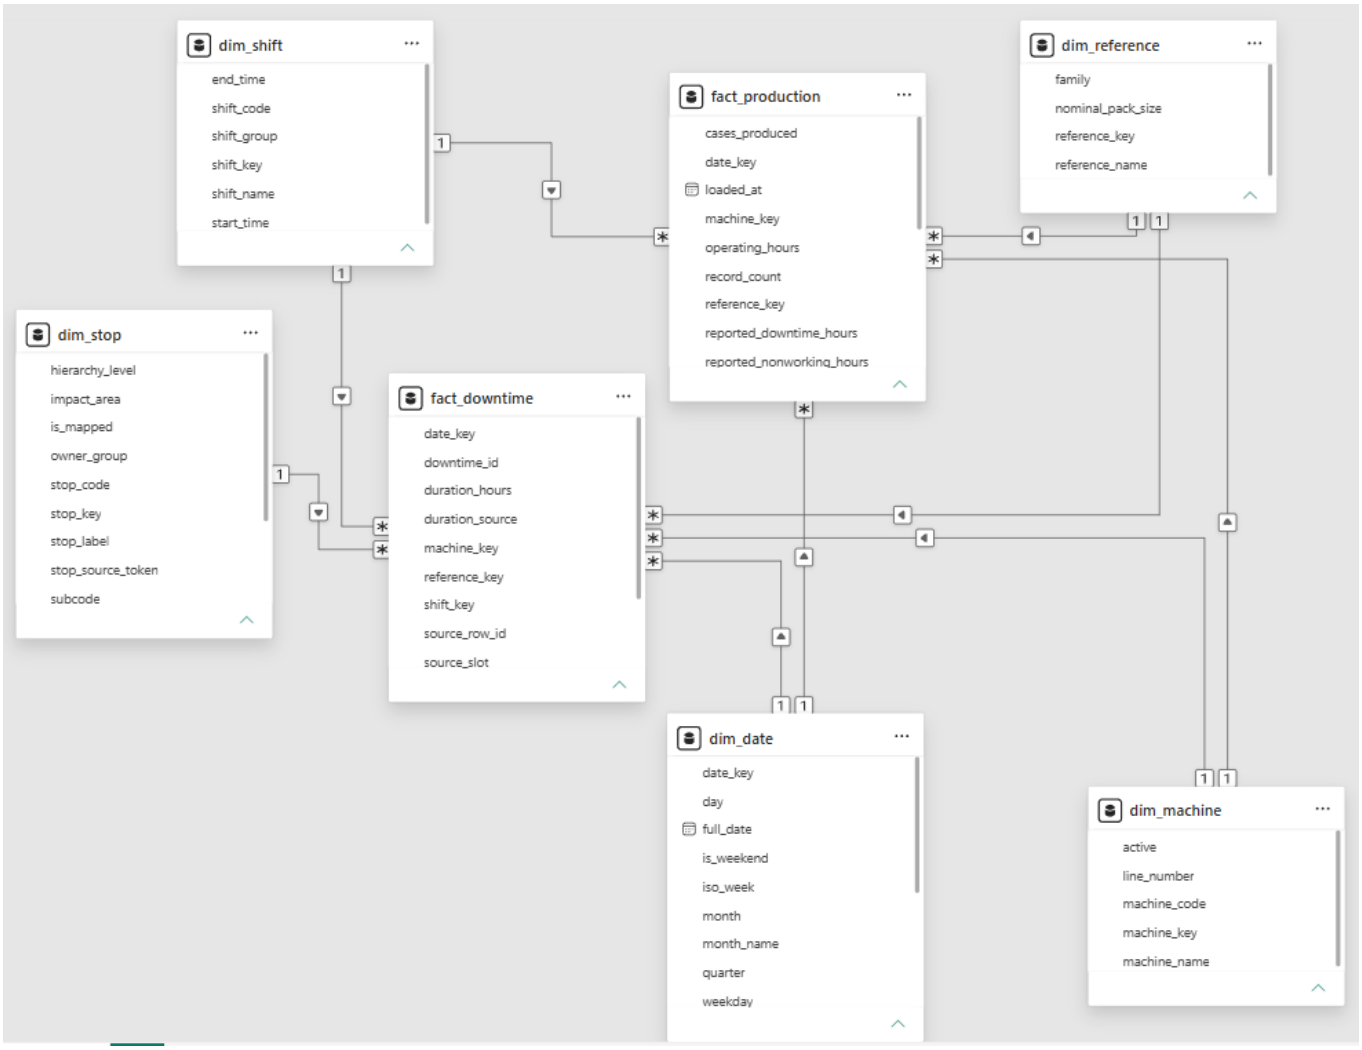


Figura 1. Modelo semántico dimensional en estrella.

Diccionario de datos y trazabilidad

La siguiente síntesis deja explícita la procedencia de cada grupo de campos. El DDL completo se entrega en sql/01_schema.sql y define los tipos, restricciones, llaves e índices.

Objeto	Columnas principales y tipos	Origen y transformación
dim_date	date_key integer PK; full_date date; día/mes/trimestre/año smallint; nombres text; is_weekend boolean.	Fecha de la fila; date_key AAAAMMDD; atributos calculados.
dim_machine	machine_key smallserial PK; machine_code/name text; line_number smallint; active boolean.	Columna máquina; catálogo validado Vinilos_1 a Vinilos_4.

Objeto	Columnas principales y tipos	Origen y transformación
dim_shift	shift_key smallserial PK; shift_code/name text; horarios time; grupo text.	Columna turno; nulo se transforma a SIN TURNO.
dim_reference	reference_key bigserial PK; reference_name text; familia/tamaño text.	Columna referencia; nulo se transforma a SIN REFERENCIA.
dim_stop	stop_key bigserial PK; tokens, códigos, etiquetas, área, responsable, nivel y bandera boolean.	Slots de causa/subcausa; mapeo a P-MTO-22 cuando es inequívoco.
fact_production	source_row_id bigint PK; cuatro FKs; cases_produced y horas numeric; source_excel_row integer; loaded_at timestamptz.	Fila Excel; números válidos o NULL; trazabilidad por fila.
fact_downtime	downtime_id bigserial PK; source_row_id bigint FK; stop_key; source_slot; duration_hours numeric; source text.	Cada slot positivo; duración de detalle o tiempo total no clasificado.
fact_live_hour	hour_start timestamptz; machine_key; minutos planificados/marcha/paro numeric; casos; source_mode text.	Simulador 24 h por línea; separado del histórico.

Trazabilidad exacta de columnas origen (Linaje Hoja Base De Datos → PostgreSQL):

- **dim_date:** Derivada íntegramente de la columna Fecha (ignorando las columnas Año, Mes, Fecha (índice de meses) y Fecha (mes) del Excel por contener inconsistencias de fórmula).
- **dim_machine:** Columna Maquina (validada contra el dominio Vinilos_1 a Vinilos_4).
- **dim_shift:** Columna Turno (nulos mapeados a SIN TURNO).
- **dim_reference:** Columna Referencia (nulos mapeados a SIN REFERENCIA).
- **fact_production:** Columnas Pacas producidas → cases_produced (NUMERIC >= 0), Horas trabajadas → operating_hours (NUMERIC >= 0), Horas no trabajadas → reported_nonworking_hours (NUMERIC >= 0), y sumatoria de control de paro → reported_downtime_hours. Se excluyen por gobierno de datos Operario y Observaciones.
- **fact_downtime y dim_stop:** Despivoteo de los pares de columnas Tipo de paro, Codigo de paro 1..17, Sub Codigo de paro y Codigo 1..17 en horas de la hoja principal, cruzados contra el catálogo oficial del procedimiento P-MTO-22 y la tabla Base_datos_subcodigos.

Restricciones e índices

El modelo usa PK, FK y unicidad para evitar eventos repetidos por slot. Las medidas de producción, operación, paro y no trabajadas se restringen a valores no negativos. Los índices date_key + machine_key, machine_key + shift_key + date_key, stop_key + source_row_id y machine_key + hour_start permiten los filtros más frecuentes de los tableros y consultas mensuales.

ETL reproducible, base de datos y consultas

Se seleccionó **Python 3.12 (openpyxl + psycopg)** contenerizado en Docker por encima de alternativas como Power Query (M) o carga directa en SQL por cuatro razones técnicas:

1. **Independencia de la capa de BI:** Si la transformación se hiciera en Power Query, los datos limpios solo existirían dentro de Power BI y no estarían disponibles en PostgreSQL para el monitoreo operativo en Grafana ni para consultas SQL en DBeaver.
2. **Despivoteo complejo de grupos repetitivos (*Unpivoting*):** La hoja Base De Datos contiene 17 pares de columnas horizontales de códigos y duraciones de paro junto con subcódigos anidados. Python permite recorrer, normalizar tokens textuales y transformar cada fila ancha en múltiples eventos normalizados (pasando de 8.208 filas de producción a 16.532 eventos en fact_downtime) en una sola pasada en memoria.
3. **Auditoría transaccional y control de concurrencia:** Permite implementar bloqueos asesores (pg_advisory_lock) en PostgreSQL y registrar métricas de calidad en formato JSON dentro de la tabla dw.etl_audit incluso cuando una ejecución falla.
4. **Reproducibilidad multiplataforma:** Al ejecutarse mediante docker compose --profile etl run --rm etl, garantiza el mismo resultado desde cero en cualquier sistema operativo sin depender de licencias ni rutas locales de Windows.

Ejecución desde cero

Paso	Ejecución
1. Fuente	Copiar el XLSM original a data/SEGUIMIENTO TEMPERAS Y VINILOS Actividad.xlsm.
2. Variables	Copiar .env.example a .env y definir claves locales.
3. Servicios	docker compose --profile container-db up -d db.
4. ETL	docker compose --profile etl run --rm etl.
5. Analítica	Ejecutar sql/02_analytics.sql para crear las vistas.
6. Grafana	docker compose up -d grafana y abrir localhost:3001.

Paso	Ejecución
7. Simulación	docker compose --profile etl run --rm etl python simulate.py --trigger.
8. Power BI	Abrir powerbi/BI_ProyectoFinal.pbip y actualizar desde PostgreSQL localhost:5433.

Consultas de negocio

vw_monthly_machine agrega pacas, horas, disponibilidad proxy y pacas por hora por máquina/año/mes. La consulta usa LAG para comparar pacas con el mes anterior. El Pareto agrega duración por causa y subcausa y emplea SUM OVER para calcular total y participación. La vista vw_downtime_detail propaga las claves conformadas de producción hacia el hecho de paro sin relacionar hechos entre sí en Power BI.

Código SQL:

```
-- 1. Comparativo intermensual por línea con funciones de ventana (LAG y promedio móvil)
SELECT
    m.machine_name,
    d.year,
    d.month,
    SUM(fp.cases_produced) AS pacas_mes,
    ROUND(SUM(fp.operating_hours), 2) AS horas_operativas,
    ROUND(
        SUM(fp.operating_hours) / NULLIF(SUM(fp.operating_hours) +
SUM(fp.reported_nonworking_hours), 0) * 100,
        2
    ) AS disponibilidad_proxy_pct,
    LAG(SUM(fp.cases_produced)) OVER (
        PARTITION BY m.machine_name ORDER BY d.year, d.month
    ) AS pacas_mes_anterior,
    ROUND(
        (SUM(fp.cases_produced) - LAG(SUM(fp.cases_produced)) OVER (PARTITION BY
m.machine_name ORDER BY d.year, d.month))
        / NULLIF(LAG(SUM(fp.cases_produced)) OVER (PARTITION BY m.machine_name ORDER BY
d.year, d.month), 0) * 100,
```

```
        2
    ) AS variacion_mensual_pct
FROM dw.fact_production fp
JOIN dw.dim_date d ON fp.date_key = d.date_key
JOIN dw.dim_machine m ON fp.machine_key = m.machine_key
GROUP BY m.machine_name, d.year, d.month
ORDER BY m.machine_name, d.year, d.month;

-- 2. Análisis de Pareto (80/20) de causas y subcausas de paro con SUM() OVER y RANK()
WITH paros_agrupados AS (
    SELECT
        s.stop_code,
        s.stop_label,
        COALESCE(s.subcode, 'SIN SUBCÓDIGO') AS subcodigo,
        ROUND(SUM(fd.duration_hours), 2) AS horas_paro
    FROM dw.fact_downtime fd
    JOIN dw.dim_stop s ON fd.stop_key = s.stop_key
    GROUP BY s.stop_code, s.stop_label, COALESCE(s.subcode, 'SIN SUBCÓDIGO')
)
SELECT
    RANK() OVER (ORDER BY horas_paro DESC) AS ranking,
    stop_code,
    stop_label,
    subcodigo,
    horas_paro,
    ROUND(horas_paro / SUM(horas_paro) OVER () * 100, 2) AS participacion_pct,
    ROUND(
        SUM(horas_paro) OVER (ORDER BY horas_paro DESC ROWS BETWEEN UNBOUNDED
PRECEDING AND CURRENT ROW)
        / SUM(horas_paro) OVER () * 100,
        2
    ) AS pareto_acumulado_pct
FROM paros_agrupados
ORDER BY horas_paro DESC;
```

Conexión y seguridad

PostgreSQL se publica solo en loopback en localhost:5433 y Grafana en localhost:3001. Las credenciales permanecen en .env, excluido de Git. Se recomiendan roles separados: ETL con escritura; Grafana y Power BI con lectura. Para ambientes compartidos, aplicar TLS, RBAC/SSO y rotación de secretos.

Grafana operativo y alerta

Grafana se conecta a PostgreSQL como datasource provisionado. El tablero tiene selector por máquina, una tarjeta de paro móvil de 60 minutos, una serie temporal de minutos de paro y marcha, y una tabla del último estado por línea. El dashboard se actualiza cada minuto.

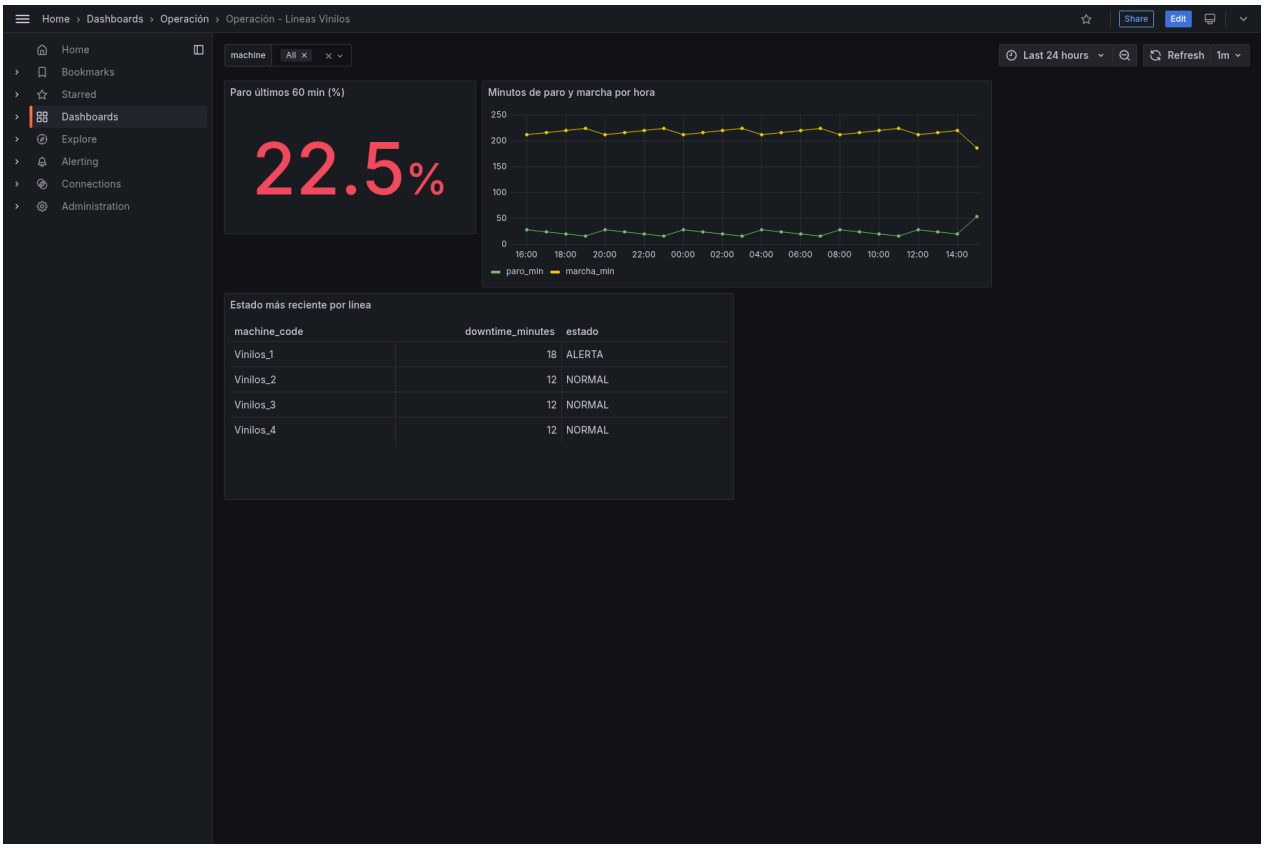


Figura 2. Tablero operativo Grafana con serie simulada y estado por línea.

Regla de alerta y simulación

La regla evalúa cada máquina por separado. Se considera Firing si el paro supera 20% de los minutos planificados en los últimos 60 minutos. En la demostración con --trigger, Vinilos_1 registra 18 minutos de paro sobre 60 planificados, equivalente a 30%, y supera el umbral. Las demás líneas pueden estar en 20% sin disparar porque la condición es estrictamente mayor que 20%.

Justificación de negocio del umbral del 20%: En el informe histórico del procedimiento **P-MTO-22**, la productividad general promedio de las líneas se sitúa en **76,3%** (lo que implica una pérdida histórica acumulada por paros del **23,7%** del tiempo, encabezada por Alimentación y aseo con 8,4%, Ajuste

operativo con 5,7% y Limpieza por derrame con 4,7%). Fijar el umbral de alerta operativa en $> 20\%$ **sobre una ventana móvil de 60 minutos** (equivalente a superar **12 minutos de paro en una hora**) permite que el supervisor de línea y mantenimiento intervengan de forma preventiva antes de que la máquina supere el promedio histórico de pérdida (23,7%) y comprometa la meta del turno.

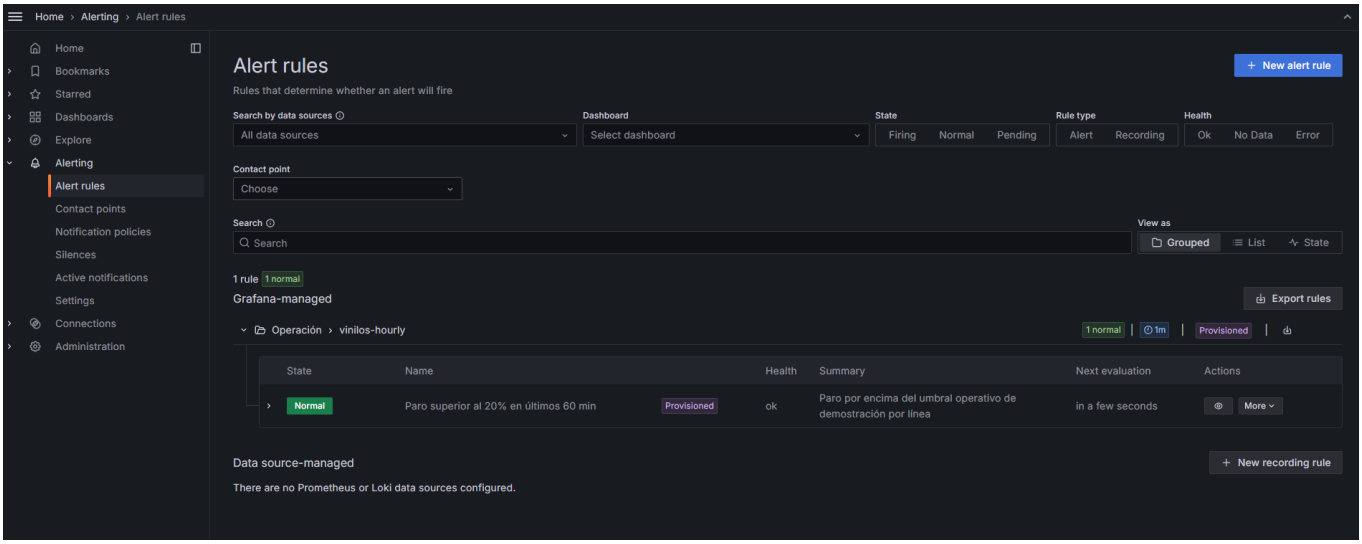


Figura 3. Evidencia de regla Grafana.

Power BI analítico

El proyecto PBIP/TMDL se conecta a PostgreSQL, no al Excel. Importa fact_production, vw_downtime_detail y las dimensiones. Las relaciones son de una dirección desde dim_date, dim_machine, dim_shift y dim_reference hacia los dos hechos; dim_stop filtra solo el hecho de paro. dim_date se usa para inteligencia de tiempo y habilita SAMEPERIODLASTYEAR para la comparación interanual.

Navegación, segmentación y profundización

El reporte se estructura en tres páginas navegables: (1) Resumen Ejecutivo, con segmentadores de año, línea, turno y referencia, tarjetas KPI, tendencia con jerarquía temporal, comparativo interanual por línea y Pareto 80/20 con drill-down causa > subcausa; (2) Pareto y Subcausas, que profundiza en el segundo nivel de la jerarquía (códigos 01, 03 y 05 del P-MTO-22), áreas de impacto y grupos responsables; y (3) Calidad y Conciliación, que audita los registros sin turno/referencia, la brecha entre horas no trabajadas y paro detallado, y el estado del OEE.

Medidas semánticas

Medida	Uso
Pacas, Horas operativas registradas y Horas no trabajadas reportadas	Agregación certificada de valores disponibles.

Medida	Uso
Disponibilidad proxy y Pacas por hora	Indicadores de registro, con denominador y límite documentados.
Paro detallado y porcentaje Pareto	Análisis de pérdidas por causa y subcausa.
Pacas año anterior y Variación interanual	Inteligencia de tiempo sobre dim_date.
OEE = BLANK()	Evita una cifra falsa mientras no exista ciclo ideal y calidad.

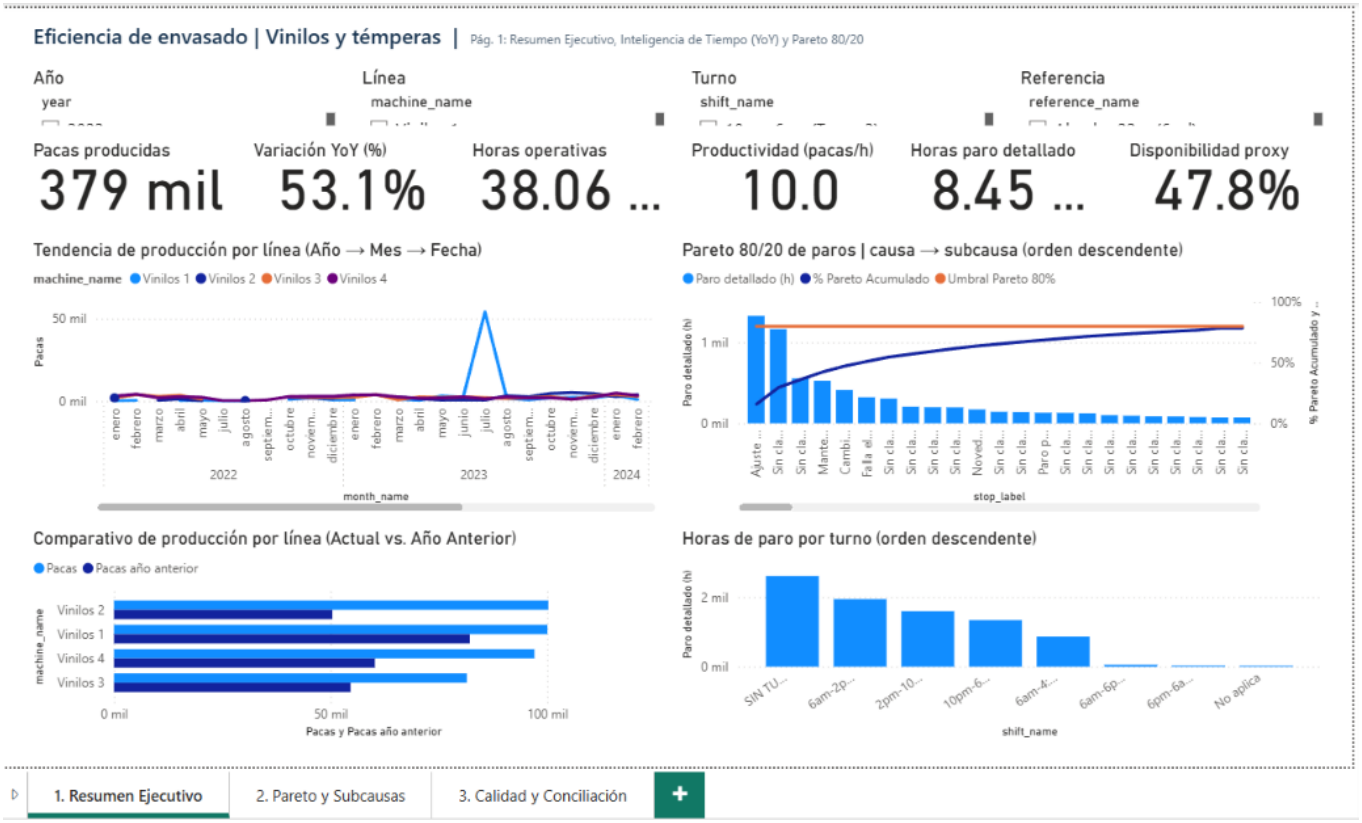


Figura 4. Power BI – Pág. 1: Resumen Ejecutivo y Pareto 80/20.

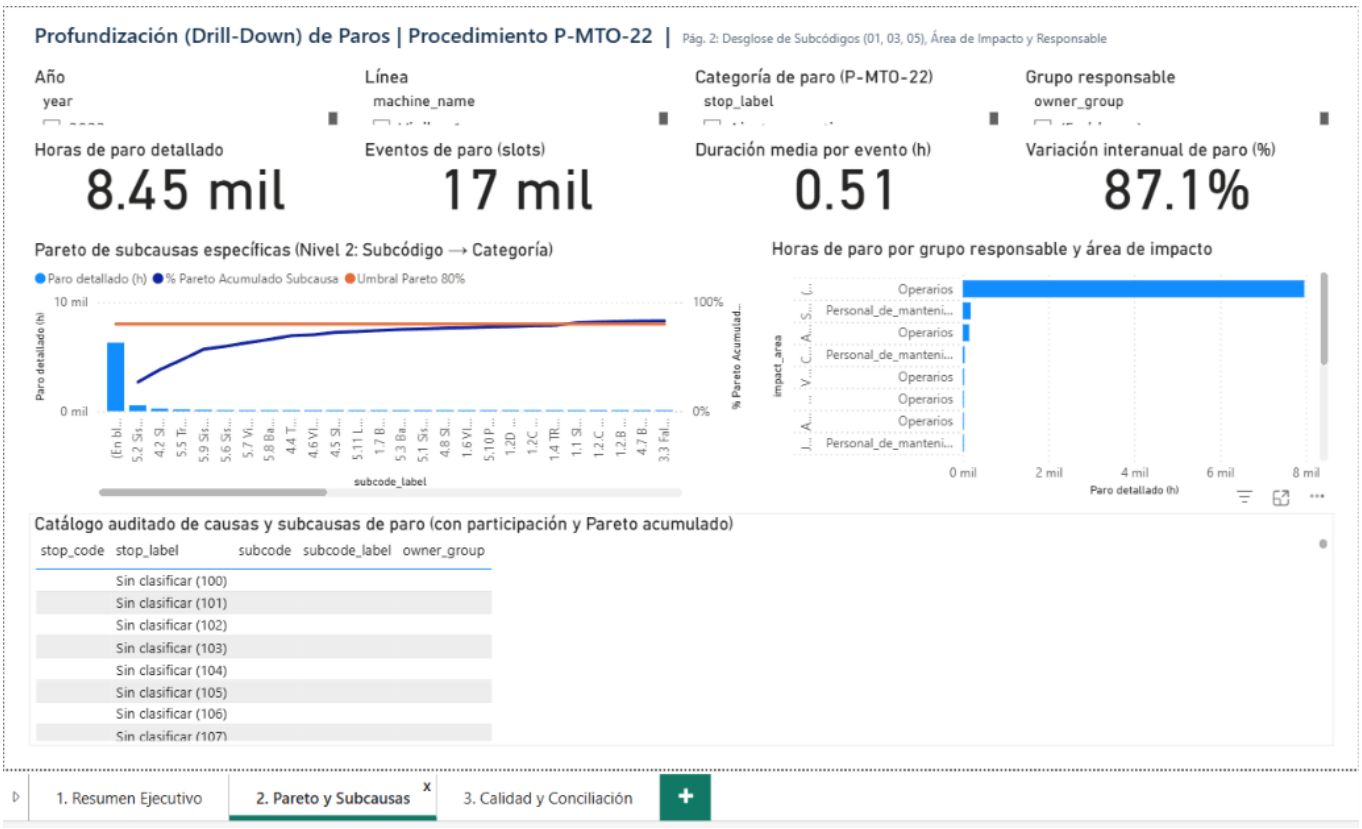


Figura 5. Power BI – Pág. 2: Drill-Down de Subcausas y Responsables.

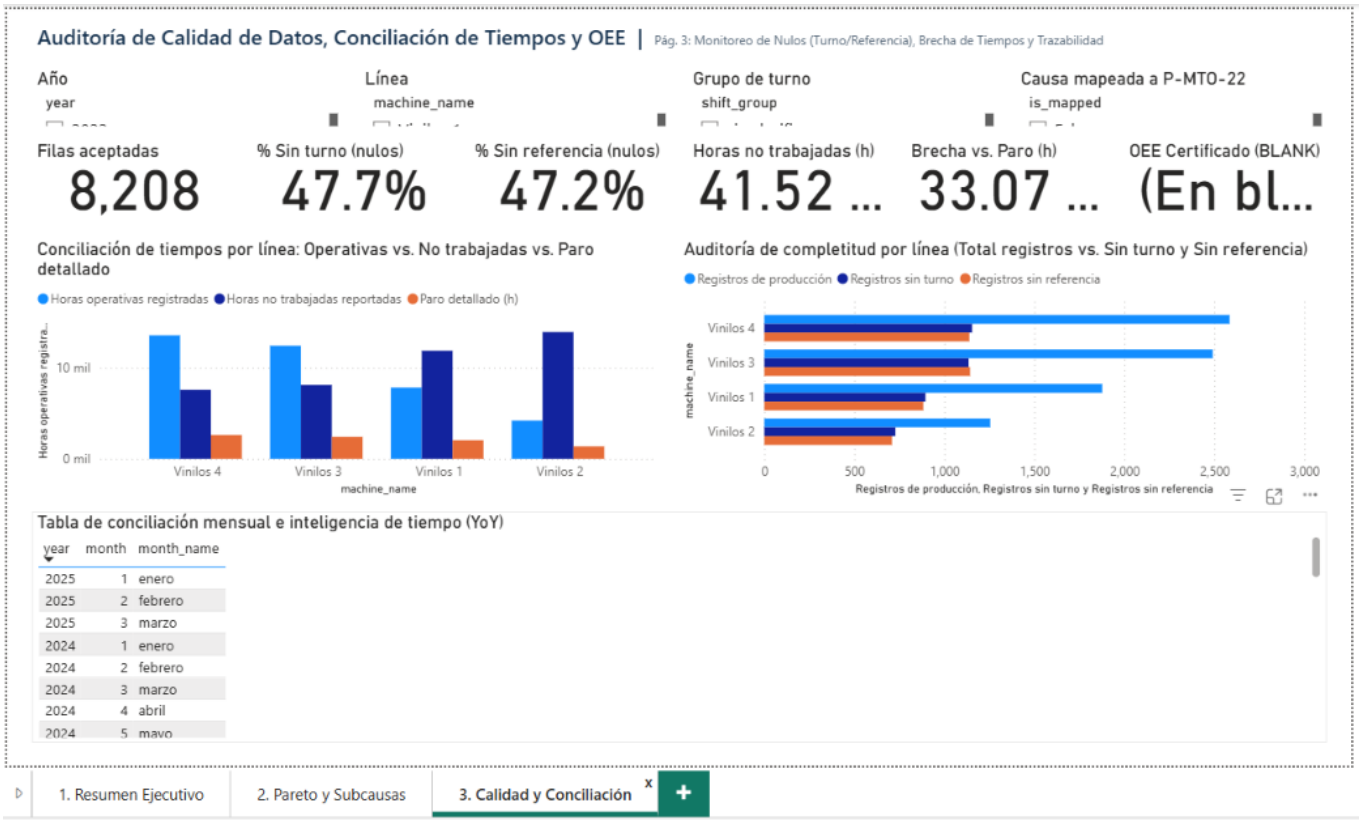


Figura 6. Power BI – Pág. 3: Calidad de Datos y Conciliación.

Medidas DAX:

En fact_production:

```
Pacas = SUM(fact_production[cases_produced])
Horas operativas registradas = SUM(fact_production[operating_hours])
Horas no trabajadas reportadas = SUM(fact_production[reported_nonworking_hours])
Horas de paro reportadas (hoja) = SUM(fact_production[reported_downtime_hours])
Disponibilidad proxy = DIVIDE([Horas operativas registradas], [Horas operativas registradas] + [Horas no trabajadas reportadas])
Pacas por hora = DIVIDE([Pacas], [Horas operativas registradas])
Pacas año anterior = CALCULATE([Pacas], SAMEPERIODLASTYEAR(dim_date[full_date]))
Variación interanual % = DIVIDE([Pacas] - [Pacas año anterior], [Pacas año anterior])
Pacas mes anterior = CALCULATE([Pacas], PREVIOUSMONTH(dim_date[full_date]))
Variación mensual % = DIVIDE([Pacas] - [Pacas mes anterior], [Pacas mes anterior])
Registros de producción = COUNTROWS(fact_production)
Registros sin turno = CALCULATE(COUNTROWS(fact_production), dim_shift[shift_code] = "SIN TURNO")
% Registros sin turno = DIVIDE([Registros sin turno], [Registros de producción])
Registros sin referencia = CALCULATE(COUNTROWS(fact_production), dim_reference[reference_name] = "SIN REFERENCIA")
% Registros sin referencia = DIVIDE([Registros sin referencia], [Registros de producción])
Brecha horas no trabajadas vs paro (h) = [Horas no trabajadas reportadas] - [Paro detallado (h)]
OEE = BLANK() -- Bloqueado hasta disponer de velocidad ideal y unidades buenas/rechazadas
```

En fact_downtime:

```
Paro detallado (h) = SUM(fact_downtime[duration_hours])
% paro Pareto = DIVIDE([Paro detallado (h)], CALCULATE([Paro detallado (h)], ALL(dim_stop)))
% Participación de paro = DIVIDE([Paro detallado (h)], CALCULATE([Paro detallado (h)], ALLSELECTED(dim_stop)))

% Pareto Acumulado =
VAR TotalParoGlobal = CALCULATE([Paro detallado (h)], ALLSELECTED(dim_stop))
VAR ParoActual = [Paro detallado (h)]
VAR TablaResumen =
  ADDCOLUMNS(
    ALLSELECTED(dim_stop[stop_label]),
    "@Horas", [Paro detallado (h)]
  )
VAR Acumulado =
  SUMX(
    FILTER(TablaResumen, [@Horas] >= ParoActual),
    [@Horas]
  )
```

```
RETURN
    DIVIDE(Acumulado, TotalParoGlobal, BLANK())

% Pareto Acumulado Subcausa =
VAR TotalParoGlobal = CALCULATE([Paro detallado (h)], ALLSELECTED(dim_stop))
VAR ParoActual = [Paro detallado (h)]
VAR TablaResumen =
    ADDCOLUMNS(
        ALLSELECTED(dim_stop[stop_label], dim_stop[subcode_label]),
        "@Horas", [Paro detallado (h)]
    )
VAR Acumulado =
    SUMX(
        FILTER(TablaResumen, [@Horas] >= ParoActual),
        [@Horas]
    )
RETURN
    DIVIDE(Acumulado, TotalParoGlobal, BLANK())

Umbral Pareto 80% = 0.80
Eventos de paro = COUNTROWS(fact_downtime)
Duración media por paro (h) = AVERAGE(fact_downtime[duration_hours])
Paro año anterior (h) = CALCULATE([Paro detallado (h)],
SAMEPERIODLASTYEAR(dim_date[full_date]))
Variación paro YoY % = DIVIDE([Paro detallado (h)] - [Paro año anterior (h)], [Paro año anterior (h)])
```

Arquitectura, despliegue y comparación de capas

La arquitectura conserva la fuente privada fuera de Git y despliega servicios reproducibles mediante Docker Compose. Las dimensiones y hechos se almacenan en PostgreSQL; DBeaver administra el esquema. Grafana y Power BI se conectan únicamente al repositorio analítico.

Fuente	Integración y almacenamiento	Consumo
Excel XLSM privado y procedimiento P-MTO-22	ETL Python + auditoría -> PostgreSQL dimensional. Docker Compose proporciona base, Grafana y perfil ETL.	Grafana operativo: hora a hora y alerta. Power BI: análisis certificado mensual/anual.

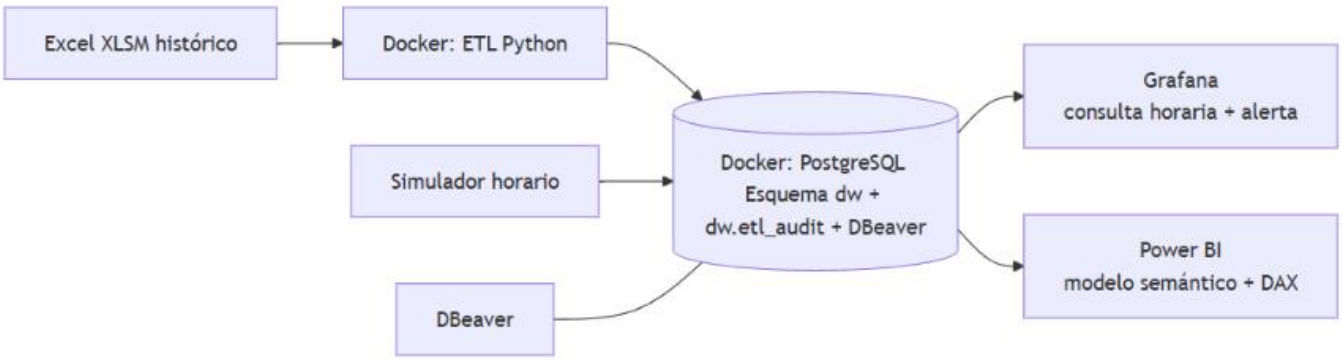


Figura 5. Diagrama de arquitectura end-to-end de la solución..

Grafana y Power BI no se intercambian

Capa	Pregunta usuario	Actualización y razón
Grafana	¿Qué línea está en riesgo ahora y se excedió el umbral? Supervisión y mantenimiento.	Cada minuto. Opera sobre fact_live_hour, filtros rápidos y alertas.
Power BI	¿Qué tendencia, referencia, turno o causa debe priorizar gerencia?	Mensual/trimestral. Modelo semántico, tiempo, Pareto y narrativa de decisión.
DBeaver PostgreSQL	¿La carga concilia y qué reglas fallaron? Analista BI.	En cada carga. Auditoría, DDL, SQL y trazabilidad.

GitHub y control de versiones

El repositorio versiona SQL, ETL, Docker Compose, dashboard y datasource Grafana provisionados, documentación y proyecto Power BI en PBIP/TMDL. Este formato Power BI se eligió sobre PBIX porque expone definiciones de texto y facilita revisión de cambios. .gitignore excluye XLSM/CSV, .env, cachés PBI y registros locales. El historial debe mostrar aportes identificables de ambos integrantes.

Evolución a PLC SCADA y cierre

Evolución propuesta

Cuando las líneas entreguen datos de PLC/SCADA, el simulador se sustituirá por ingesta de eventos OPC UA o MQTT. Cada evento debe conservar timestamp con zona horaria, máquina, estado, contador de producción, código, secuencia y calidad de señal. Una capa de streaming con buffer y reintentos alimentará eventos crudos y agregados por minuto/hora. Producción e Ingeniería deberán definir formalmente tiempo planificado, paros planificados, microparos, ciclo ideal y conteos bueno/rechazado para calcular OEE completo.

Gobierno de datos, tratamiento de datos personales (Ley 1581 de 2012) y seguridad de acceso: En el formato físico F-PRO-33 (campo *Nombre Líder*, donde figuran nombres propios como *"Natalia P., Erica R., Lorena T., Carlos Arqueta"*) y en las hojas del libro XLSM (columnas Operario y Personal involucrado), se almacenan datos personales que identifican directamente a trabajadores de planta y técnicos de mantenimiento.

En cumplimiento del **principio de minimización y finalidad de la Ley Estatutaria 1581 de 2012 (Protección de Datos Personales en Colombia)**, y dado que el objetivo de la solución de BI es evaluar la eficiencia de los **activos productivos (líneas, turnos, referencias y causas de paro)** y no auditar individualmente a las personas:

1. **Anonimización y exclusión en origen (Privacy by Design):** El proceso ETL en Python omite deliberadamente la extracción de las columnas Operario y Personal involucrado, evitando que datos nominales ingresen a PostgreSQL, Grafana o Power BI. En dim_stop, la atribución operativa se conserva únicamente a nivel de rol institucional (Operarios vs. Personal_de_mantenimiento).
2. **Seguridad del repositorio y credenciales:** El archivo fuente .xlsm y el archivo .env están excluidos del control de versiones mediante .gitignore, evitando exponer datos sensibles o contraseñas en GitHub.
3. **Control de acceso basado en roles (RBAC) y red:** El motor PostgreSQL expone su puerto únicamente en la interfaz local (127.0.0.1:5433), segregando privilegios entre el rol de carga (etl_writer con permisos DML sobre el esquema dw) y el rol de consumo (bi_reader con permisos SELECT exclusivos sobre vistas y tablas dimensionales para Power BI y Grafana).

Recomendaciones para gerencia

- Aprobar la definición oficial de horas no trabajadas y del denominador de disponibilidad.
- Hacer obligatorio el turno y la referencia en el registro para reducir los nulos que limitan el análisis.
- Revisar las categorías heredadas y publicar un catálogo de causas único con dueño, área e impacto.
- Definir captura de ciclo ideal y unidades buenas/rechazadas antes de usar OEE como indicador de desempeño.